

EduFocus

Méthodes statistiques, apprentissage machine et data mining

Un cours appliqué : les mathématiques derrière l'analyse

de l'exclusion scolaire en Mauritanie

Projet EduFocus – Datathon IndabaX Mauritanie 2026

*Ce document est un cours qui explique **pourquoi** et **comment** chaque méthode est utilisée dans EduFocus : d'abord l'idée, ensuite la **formule mathématique**, puis **où** elle intervient dans le code, l'API et l'interface.*

Table des matières

1	Introduction : le problème et les trois familles de méthodes	2
2	Statistiques descriptives et inférentielles	2
2.1	Normalisation min-max	2
2.2	Standardisation z-score	2
2.3	Transformation logarithmique	3
2.4	Médiane et partage en quadrants	3
2.5	Corrélation de Pearson	3
2.6	Concentration : Pareto, Lorenz et indice de Gini	4
2.7	Tendance et régression linéaire simple (moindres carrés)	5
3	Apprentissage machine non supervisé : typologie des wilayas	5
3.1	K-means	5
3.2	Choisir k : inertie (coude) et silhouette	5
4	Apprentissage machine supervisé : les déterminants individuels	6
4.1	Régression logistique	6
5	Data mining : règles d'association (Apriori)	7
6	Analyse de graphes et détection de communautés	8
6.1	Représentation en graphe	8
6.2	Détection de communautés : Louvain	8
6.3	Layout $\hat{n}$ force-directed $\hat{z}$ (carte du graphe)	9
7	Indicateur composite : l'Indice de Priorité Éducative (IPE)	9
8	Scénarios prospectifs à 2030	10
9	Récapitulatif : méthode $\leftrightarrow$ où c'est utilisé	10
10	Bibliothèque logicielle	10

1 Introduction : le problème et les trois familles de méthodes

EduFocus analyse l'exclusion scolaire en Mauritanie : **375 566 enfants de 6–14 ans** (soit **33,1 %**) sont hors de l'école formelle selon l'enquête EPCV 2019, sur une population cible de 1 135 657 enfants répartis dans les **13 wilayas**.

Pour transformer ces données brutes en décisions d'investissement, le projet utilise trois familles de méthodes complémentaires :

1. **Statistiques** : décrire (moyennes, médianes, concentration) et mesurer les liaisons entre indicateurs (corrélation de Pearson).
2. **Apprentissage machine** : *non supervisé* pour regrouper les wilayas (K-means, silhouette) et *supervisé* pour expliquer les déterminants individuels (régression logistique).
3. **Data mining et graphes** : règles d'association (Apriori) et analyse de réseaux (détection de communautés de Louvain) pour découvrir des structures non évidentes.

Fil rouge. Chaque méthode est décrite dans ce cours comme suit : *idée* → *formule* → *exemple chiffré* → où c'est utilisé. Un tableau récapitulatif complet est donné au § 9.

2 Statistiques descriptives et inférentielles

2.1 Normalisation min–max

Idée. Les indicateurs n'ont pas la même unité (un taux en %, un effectif en milliers, un ratio sans dimension). Pour les comparer et les combiner, on les ramène sur une échelle commune [0, 100].

Formule

$$x'_i = \frac{x_i - \min(x)}{\max(x) - \min(x)} \times 100$$

où $\min(x)$ et $\max(x)$ sont les valeurs extrêmes observées sur les 13 wilayas. Si $\max(x) = \min(x)$ (pas de variation), on fixe $x'_i = 50$.

Où c'est utilisé dans EduFocus

`backend/analytics/index.py` – fonction `normalize()` : normalise le **volume** (nombre d'enfants hors école, en échelle log, cf. 2.3) et l'**intensité** (taux de hors-école) avant de construire l'indice IPE (§ 7). Accessible via `/api/wilayas` et affiché sur la page `/wilayas`, la carte `/carte` et le rapport `/rapport`.

2.2 Standardisation z-score

Idée. Pour un *clustering*, les données doivent être centrées et réduites : chaque variable doit avoir la même échelle, sinon les variables grandes en valeur domineraient les calculs de distance.

Formule

$$z_i = \frac{x_i - \mu}{\sigma}, \quad \mu = \frac{1}{n} \sum_{i=1}^n x_i, \quad \sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}.$$

Après transformation : moyenne 0, écart-type 1.

Où c'est utilisé dans EduFocus

`backend/analytics/clustering.py` – `StandardScaler().fit_transform(...)` sur 8 features (intensité, pauvreté, ruralité, dépendance jeunes, mahadra, aucune instruction, écart de genre, densité d'écoles) avant le K-means (§ 3.1).

2.3 Transformation logarithmique

Idée. Le nombre d'enfants hors école varie de quelques milliers (Nouadhibou) à des centaines de milliers (Hodh Ech Chargui). Une échelle logarithmique $\ln$ compresse $\hat{z}$ les grands nombres et rend la variable symétrique.

Formule

$$y = \log(1 + x) \quad (\log1p)$$

Le $+1$ garantit que $x = 0 \mapsto y = 0$. Utilisée avant la normalisation min-max du *volume* et dans la matrice de stratégie.

Où c'est utilisé dans EduFocus

`backend/analytics/index.py` (`np.log1p`) et `backend/analytics/matrice.py` (axe $\ln$ volume $\hat{z}$ du scatter). Page `/strategies`.

2.4 Médiane et partage en quadrants

Idée. La médiane coupe une distribution en deux moitiés égales. Elle est robuste aux valeurs extrêmes (contrairement à la moyenne).

Définition

Pour un échantillon trié $x_{(1)} \leq \dots \leq x_{(n)}$:

$$\text{médiane} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ impair} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & \text{si } n \text{ pair.} \end{cases}$$

Où c'est utilisé dans EduFocus

`backend/analytics/matrice.py` : chaque wilaya est classée *haut/bas* selon la médiane du volume log et la médiane de l'intensité $\rightarrow$ **4 quadrants** ($\ln$ Effort massif $\hat{z}$, $\ln$ Ciblage des effectifs $\hat{z}$, $\ln$ Traitement local $\hat{z}$, $\ln$ Consolidation $\hat{z}$). Page `/strategies`, endpoint `/api/matrice`.

2.5 Corrélation de Pearson

Idée. Mesure la force et le sens de la *liaison linéaire* entre deux indicateurs, en unités normalisées (donc comparable entre paires).

Formule

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$

Propriétés : $r \in [-1, 1]$; $r = 1$ (resp. -1) : corrélation linéaire positive (resp. négative) parfaite ; $r = 0$: aucune liaison linéaire.

Ce que r mesure et ne mesure pas. La corrélation est *symétrique* et *sans direction de causalité* : si le taux de pauvreté et le taux de hors-école corrélient à $r = 0,84$, cela ne prouve pas que la pauvreté *cause* le hors-école. C'est le rôle de la régression logistique (§ 4.1) d'approcher la causalité en *ajustant* les facteurs.

Où c'est utilisé dans EduFocus

Trois usages :

- `backend/analytics/indicateurs.py` : matrice complète 12×12 affichée en heatmap sur `/indicateurs` et `/rapport` (endpoint `/api/indicateurs`). Paires les plus fortes : dépendance jeunes $\times$ part 0-14 ans ($r = 1,00$), aucune instruction $\times$ adultes 15+ sans instruction ($r = 0,94$), ruralité $\times$ dépendance jeunes ($r = 0,91$).
- `backend/analytics/graph.py` : réseau de similarité entre wilayas (profils centrés-réduits, $|r| > 0,70$, top-2 voisins) et graphe de corrélations entre indicateurs ($|r| > 0,75$). Page `/reseau`.
- `backend/analytics/concentration.py` : n'utilise pas r mais quantifie la concentration (voir § 2.6).

2.6 Concentration : Pareto, Lorenz et indice de Gini

Idée. Le hors-école n'est pas uniformément réparti. On veut savoir **combien de wilayas portent la moitié du problème** et mesurer l'inégalité de la répartition (loi de Pareto n° 20 % des zones $\rightarrow$ 80 % du problème $\hat{z}$).

Formules

Courbe de Lorenz (part cumulée) : on trie $x_{(1)} \geq \dots \geq x_{(n)}$ par ordre décroissant, alors

$$\text{Lorenz}(k) = \frac{\sum_{i=1}^k x_{(i)}}{\sum_{i=1}^n x_{(i)}} \times 100.$$

Indice de Gini (formule par paires, utilisée dans le code) :

$$G = \frac{\sum_{i=1}^n \sum_{j=1}^n |x_i - x_j|}{2n \sum_{i=1}^n x_i}.$$

Interprétation : $G = 0$ répartition parfaitement égale, $G = 1$ concentration totale. G est lié à l'aire entre la courbe de Lorenz et la diagonale (égalité parfaite).

Où c'est utilisé dans EduFocus

`backend/analytics/concentration.py` : calcule la part cumulée des 5 premières wilayas (**top5**), le nombre de wilayas pour atteindre 50 % du problème, la courbe de Lorenz et le Gini. Endpoints `/api/concentration` ; affiché sur `/` (Home), `/strategies` et `/rapport`.

2.7 Tendance et régression linéaire simple (moindres carrés)

Idée. Pour projeter le taux de hors-école jusqu'en 2030, on mesure la pente de la tendance passée (World Bank, 2008–2024) par régression linéaire.

Formule

Modèle $y = \beta_0 + \beta_1 x + \varepsilon$. Le moindre carré minimise $\sum_i (y_i - \beta_0 - \beta_1 x_i)^2$, solution :

$$\beta_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}.$$

Où c'est utilisé dans EduFocus

`backend/analytics/scenarios.py` – `np.polyfit(x, y, 1)` : pente annuelle bornée dans $[-1, 0, 0]$ points par an, prolongée sur 2030 – 2022 ans. Endpoint `/api/scenarios`, page `/strategies`. Les séries brutes WDI sont servies par `/api/trends` sur `/tendances`.

3 Apprentissage machine non supervisé : typologie des wilayas

3.1 K-means

Idée. Regrouper les 13 wilayas en k classes homogènes selon leurs 8 indicateurs normalisés. Deux wilayas d'une même classe ont des profils d'exclusion proches $\Rightarrow$ la même stratégie d'investissement.

Algorithme et objectif

On minimise l'*inertie* (somme des distances quadratiques intra-classe) :

$$J = \sum_{c=1}^k \sum_{i \in C_c} \|x_i - \mu_c\|^2.$$

Algorithme itératif (Lloyd) :

1. initialiser k centres μ_c aléatoirement ;
2. **affectation** : $C_c \leftarrow \{i : c = \arg \min_c \|x_i - \mu_c\|\}$;
3. **mise à jour** : $\mu_c \leftarrow \frac{1}{|C_c|} \sum_{i \in C_c} x_i$;
4. répéter 2–3 jusqu'à convergence (inertie stable).

Où c'est utilisé dans EduFocus

`backend/analytics/clustering.py` : `KMeans(n_clusters=k, n_init=20)` sur données z-scorées. $k = 3$ retenu pour une typologie lisible (modérée / dominante / aucune instruction). Endpoint `/api/clusters`, pages `/clusters`, `/wilayas` et `/rapport`.

3.2 Choisir k : inertie (coude) et silhouette

Idée. L'inertie $J(k)$ décroît toujours avec k ; le bon k est celui où la courbe se casse (méthode du coude). La *silhouette* mesure la cohésion d'un point avec sa classe par rapport à la classe voisine.

Silhouette

Pour chaque point i :

$a(i)$ = distance moyenne aux points de sa propre classe,

$b(i)$ = min des distances moyennes aux autres classes,

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, 1].$$

$s(i) \approx 1$: point bien classé ; $s(i) < 0$: point probablement mal affecté. On choisit le k qui maximise la *silhouette moyenne*.

Où c'est utilisé dans EduFocus

`backend/analytics/clustering.py` – `choose_k()` balaye $k \in [2, 6]$, calcule inerties + `silhouette_score` ; le k optimal est ensuite raffiné pour la lisibilité (voir la note dans `run_all.py`).

4 Apprentissage machine supervisé : les déterminants individuels

4.1 Régression logistique

Idée. Prédire une variable *binnaire* – `hors_ecole` (0/1) pour chaque enfant de 6–14 ans de l'EPCV (16 451 enfants) – en fonction de facteurs : sexe, âge, milieu, pauvreté, éducation du chef de ménage, wilaya.

Modèle

La probabilité d'être hors école s'écrit avec la fonction logistique :

$$p = P(y = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}}.$$

Ou, en logit (log des cotes) :

$$\log \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p.$$

Les β sont estimés par **maximum de vraisemblance** : on maximise $L(\beta) = \prod_i p_i^{y_i} (1 - p_i)^{1-y_i}$.

Odds-ratio et intervalle de confiance

Le *odds-ratio* de la variable x_j est

$$OR_j = e^{\beta_j},$$

avec intervalle de confiance à 95 % $[e^{\beta_j - 1,96 SE_j}, e^{\beta_j + 1,96 SE_j}]$.

- $OR > 1$: le facteur *augmente* la probabilité d'exclusion ;
- $OR < 1$: il la *réduit* ;
- tous les effets sont *ajustés* : à toutes choses égales par ailleurs.

Où c'est utilisé dans EduFocus

`backend/analytics/logit.py` : `sm.Logit(...)` de `statsmodels`, avec variables binaires (références : garçon, 10–14 ans, urbain, non pauvre, Nouakchott). Résultats : `odds_ratio`, `IC`, `pvalue`, `pseudo_r2`, `aic`. Endpoint `/api/logit`, affiché sur `/` (Home) et `/rapport`. Exemple de lecture : un enfant en milieu rural a un $OR > 1$ par rapport à l'urbain, à *sexe*, *âge*, *pauvreté* et *wilaya égaux*.

Variable écartée et pseudo- R^2

La variable `nivcm`, étiquetée `1` Niveau d'éducation du CM `2` dans le fichier SPSS, n'est **pas** l'éducation parentale : le croisement `C4N` $\times$ `nivcm` sur les 60 600 individus est exactement bloc-diagonal, c'est-à-dire un simple regroupement du niveau d'instruction *de l'individu lui-même*. L'introduire dans le modèle reviendrait à régresser `1` hors école `2` sur `1` n'a aucun niveau scolaire `2` : une tautologie, qui explique la séparation complète observée. Elle est donc écartée du logit comme des règles d'association. Le fichier fourni ne contient aucune variable d'éducation parentale, et cet effet n'est pas estimable ici.

$$\text{pseudo-}R_{\text{McFadden}}^2 = 1 - \frac{\ln L(\text{modèle complet})}{\ln L(\text{modèle constant})}, \quad \text{AIC} = 2p - 2 \ln L.$$

5 Data mining : règles d'association (Apriori)

Idee. Trouver des *combinaisons de facteurs* fréquemment associées au hors-école, sans hypothèse a priori : âge, sexe, milieu rural, pauvreté, région $\rightarrow$ hors école.

Support, confiance, lift

Pour une règle $A \Rightarrow B$ (ici $B = \{\text{hors école}\}$) :

$$\text{support}(A \Rightarrow B) = \frac{\text{freq}(A \cup B)}{N}, \quad \text{confiance}(A \Rightarrow B) = \frac{\text{support}(A \cup B)}{\text{support}(A)},$$

$$\text{lift}(A \Rightarrow B) = \frac{\text{confiance}(A \Rightarrow B)}{\text{support}(B)}.$$

- *Support* : fréquence de la combinaison dans la population ;
- *Confiance* : probabilité de B sachant A ;
- *Lift* : rapport à l'indépendance. $\text{lift} > 1$: A rend B *plus probable* qu'au hasard ; c'est le critère de pertinence utilisé ici (seuil $> 1,05$).

Algorithme Apriori

1. générer les *itemsets* de taille 1 dont le support dépasse `min_support` ;
2. construire itérativement les itemsets de taille $k + 1$ par *jointure* d'itemsets de taille k (propriété d'anti-monotonie : tout sur-ensemble d'un itemset non fréquent est non fréquent) ;
3. produire les règles et ne garder que celles satisfaisant `min_confidence` et un $\text{lift} > 1$.

Où c'est utilisé dans EduFocus

backend/analytics/rules.py : `apriori()` et `association_rules()` de `mlxtend` sur les 16 451 enfants. Filtres : conséquence = exactement `{hors_ecole}`, lift > 1,05. Endpoints : `/api/rules`. **Page utilisée** : `/regles` (page dédiée du frontend), qui affiche les règles triées par lift, les profils socio-démographiques les plus sûrs (*top_confiance*) et les règles par région (*par_region*). Résultat : 21 règles non triviales, la plus forte étant `{rural, 6-9 ans, Sud-Est}` $\Rightarrow$ hors école, à **69,5 % de confiance et lift 2,10**. Aucune règle n'atteint 100 % : les règles déterministes de la version précédente provenaient uniquement de la variable tautologique `nivcm` (cf. § 4.1).

6 Analyse de graphes et détection de communautés

6.1 Représentation en graphe

Idée. Un *graphe* $G = (V, E)$ est un ensemble de nuds V (wilayas ou indicateurs) reliés par des arêtes E pondérées (par $|r|$). La structure du graphe révèle des groupes, des hubs et des isolés invisibles dans un tableau.

Degré et matrice d'adjacence

Le *degré* $\deg(v)$ d'un nud est le nombre de ses voisins. La *matrice d'adjacence* A vaut $A_{uv} = 1$ si $(u, v) \in E$, et la matrice *pondérée* $W_{uv} = |r_{uv}|$ sinon 0. Le degré (pondéré) est $\deg(v) = \sum_u W_{uv}$. Dans EduFocus, le degré des indicateurs détermine la *taille des nuds* du graphe.

Où c'est utilisé dans EduFocus

backend/analytics/graph.py :

- **Réseau de similarité des wilayas** : nuds = wilayas, arêtes = paires dont $|r| \geq 0,85$ (top-2 voisins), poids = $|r|$.
- **Graphe de corrélations des indicateurs** : nuds = indicateurs, arêtes si $|r| \geq 0,75$, taille des nuds $\propto$ degré. Endpoints `/api/graph/similarite` et `/api/graph/correlations`; page `/reseau`.

6.2 Détection de communautés : Louvain

Idée. Regrouper les wilayas qui partagent le même profil d'exclusion. La méthode de *Louvain* maximise la *modularité* Q .

Modularité de Newman–Girvan

$$Q = \frac{1}{2m} \sum_{u,v} \left[W_{uv} - \frac{d_u d_v}{2m} \right] \delta(c_u, c_v),$$

avec $m = \frac{1}{2} \sum_{u,v} W_{uv}$ (poids total des arêtes), d_u le degré pondéré de u , et $\delta(c_u, c_v) = 1$ si u et v sont dans la même communauté. $Q \in [-1, 1]$; $Q > 0,3$ indique une structure communautaire réelle (meilleure que le hasard).

Algorithme de Louvain

1. **Phase locale** : chaque nud est déplacé vers la communauté voisine qui augmente le plus Q (gain de modularité), jusqu'à stabilisation ;
2. **Agrégation** : les communautés deviennent des super-nuds ;
3. on répète 1–2 jusqu'à convergence.

Où c'est utilisé dans EduFocus

backend/analytics/graph.py : `community_louvain.best_partition(G, random_state=42)` (python-louvain). Résultat : **3 communautés** de wilayas au profil proche, exposées sur /reseau (couleurs des nuds) et dans le rapport PDF /rapport.

6.3 Layout à force-directed (carte du graphe)

Idée. Positionner les nuds dans le plan en simulant un système de forces physique : les arêtes tirent les nuds (ressorts), les nuds se repoussent (répulsion de Coulomb).

Force dirigée (modèle ressort)

Force de ressort entre nuds reliés : $F_s = k_s (d - l_0)$ (Hooke) ; répulsion entre tous les nuds : $F_r = \frac{k_r}{d^2}$; amortissement η : on itère $v += (F_s + F_r)/m$, $x += \eta v$. La position finale est une lecture visuelle de la structure : wilayas connectées se rapprochent, communautés forment des groupes visibles.

Où c'est utilisé dans EduFocus

Frontend : frontend/src/lib/charts.ts (`forceGraph()`) avec ECharts (layout *force*). Taille des nuds wilayas $\propto$ nombre d'enfants hors école ; page /reseau.

7 Indicateur composite : l'Indice de Priorité Éducative (IPE)

Idée. Combiner trois dimensions en une note 0–100 pour classer les wilayas : volume du problème, intensité de l'exclusion, vulnérabilité du territoire.

Formule

$$\text{IPE} = 0,40 \text{ Volume} + 0,35 \text{ Intensité} + 0,25 \text{ Vulnérabilité}$$

avec (toutes normalisées en 0–100, voir § 2.1) :

- Volume = $\log(1 + \text{enfants hors école})$ normalisé ;
- Intensité = taux hors école (%) normalisé ;
- Vulnérabilité = $0,75 \text{ pauvreté} + 0,25 \text{ dépendance jeunes}$.

Le rang est la *position décroissante* de l'IPE sur les 13 wilayas (méthode min pour les ex æquo).

Où c'est utilisé dans EduFocus

backend/analytics/index.py (`build_index()`) : classe les wilayas et dérive un *levier d'action* dominant par règles de seuil (construire des écoles / passerelles mahadra / rétention). Endpoints /api/summary et /api/wilayas ; utilisé sur /, /wilayas, /carte (choro-

plèthe) et /rapport.

8 Scénarios prospectifs à 2030

Idée. Traduire les leviers en trajectoires chiffrées : tendance à laisser-faire $\dot{z}$, passerelles mahadra $\rightarrow$ formel (25 % et 50 %), construction d'écoles de proximité.

Projection

Avec $\tau_0 = 33,1\%$ (2022), pente annuelle β (§ 2.7) et $n_y = 2030 - 2022$:

$$\tau_{2030} = \max(\tau_0 + \beta n_y, 0)$$

puis, si l'on convertit une part s des M_0 enfants mahadra (199 493) vers le formel :

$$\tau_{2030} \leftarrow \tau_{2030} - \frac{s M_0}{P_{6-14}} \times 100$$

où $P_{6-14} = 1\,135\,657$. Besoin en écoles : on cible une densité de 1 établissement pour 1 000 enfants, $\text{besoin}_w = \max(1 - d_w, 0) \times \frac{\text{pop}_{6-14}^{(w)}}{1000}$, et coût estimé à 25 MMRO par établissement.

Où c'est utilisé dans EduFocus

`backend/analytics/scenarios.py` : 4 scénarios comparés (taux et effectifs 2030, réduction vs 2022, coûts). Endpoint `/api/scenarios`, page `/strategies` et rapport `/rapport`.

9 Récapitulatif : méthode $\leftrightarrow$ où c'est utilisé

Lecture croisée. Les méthodes ne sont pas isolées : la normalisation alimente le clustering et l'IPE ; la corrélation alimente les graphes ; les règles d'association compensent la limite de la régression (séparation complète). L'IPE hiérarchise, le **clustering** regroupe, les **graphes** révèlent la structure, la **logistique** explique les causes individuelles, et les **scénarios** chiffrant les actions.

10 Bibliothèque logicielle

EduFocus – Datathon IndabaX Mauritanie 2026. Données : EPCV 2019 (ONS), World Bank (WDI), 13 wilayas.

Famille	Méthode	Backend	Endpoint	Pages
Stat.	Normalisation min-max	index.py	/api/wilayas	/, /wilayas, /carte, /rapport
Stat.	z-score	clustering.py	/api/clusters	/clusters, /wilayas, /rapport
Stat.	log1p	index.py, matrice.py	/api/wilayas, /api/matrice	/strategies
Stat.	Médianes (quadrants)	matrice.py	/api/matrice	/strategies, /rapport
Stat.	Corrélation de Pearson	indicateurs.py, graph.py	/api/indicateurs, /api/graph/*	/indicateurs, /reseau, /rapport
Stat.	Pareto / Lorenz / Gini	concentration.py	/api/concentration	/, /strategies, /rapport
Stat.	OLS (tendance)	scenarios.py	/api/scenarios	/strategies, /rapport
ML non sup.	K-means + silhouette	clustering.py	/api/clusters	/clusters, /wilayas, /rapport
ML sup.	Régression logistique	logit.py	/api/logit	/, /rapport
DM	Apriori (règles)	rules.py	/api/rules	/regles
Graphe	Louvain (communautés)	graph.py	/api/graph/similarities	/reseau
Graphe	Force-directed (ECharts)	—	—	/reseau
Index	IPE composite	index.py	/api/summary	/, /wilayas, /carte, /rapport
Prospectif	Projections 2030	scenarios.py	/api/scenarios	/strategies, /rapport

TABLE 1 – Correspondance complète méthode → code → API → interface.

Bibliothèque	Rôle	Méthodes mobilisées
numpy / pandas	calcul	vecteurs, agrégats, tableaux
scipy	statistiques	linkage (CAH), distributions
scikit-learn	ML	KMeans, StandardScaler, silhouette_score
statsmodels	stats	Logit (régression logistique, IC, p)
networkx	graphes	Graph, degree
python-louvain	graphes	best_partition (Louvain)
mlxtend	data mining	apriori, association_rules
pyreadstat	données	lecture EPCV 2019 (.sav)
fastapi / uvicorn	API	exposition des résultats

TABLE 2 – Bibliothèques Python utilisées par le backend (backend/requirements.txt).